

RL0-1-数据生产规范GuidelineV1.1-20260920 for外部供应商

参考文档：

- 原始文档（专家社区）：[RL0-1-数据生产规范GuidelineV1.1](#)
- Harbor格式（**Harbor格式重点**）：[外发版-评测题包交付规范（rewardkit）20260913](#)

注意：需要和评测题目交付规范组合使用。

版本	日期	负责人	说明
V1.0	2026年9月20日	予翊、砚基	根据新增的RL数据需求、平台操作流程等补充。 默认为黑色字体。 红色为强调内容。

1. 项目背景与使用范围

- 本文件定义该RL从0到1标注生产下数据的规格、格式、质量标准与验收流程。
- 适用对象：提供标注数据的所有数据生产流程。
- 面向对象：**供应商、高校**、内外部专家、标注质检平台。
- 写给专家/供应商：
 - 作为对应办公场景的专家，你熟悉该领域的任务要求，熟悉该领域办公目标实现的产物标准。
 - 你的工作是根据自己擅长的领域，选择合适难度的任务，给出能对应办公场景、具备真实业务价值的**任务描述**，并且给出恰当的**参考文件**，以及对应该任务的**参考答案**。同时你需要针对该任务，给出一套能衡量任务做得好坏的**打分项**。
 - 我们会根据你给的打分项
 - ① 对你提交的参考答案打分，看得分是否足够高（正确率>0.85）；
 - ② 用3个模型执行你给出的任务，并用你给出的打分项打分，看难度是否足够高（三模型平均正确率<0.7）。
 - 此外，人工质检会重点考察题目真实性、参考答案合理性、打分项设计合理性、是否hack等异常作弊情况，一经发现，直接打回。
 - 供应商的题目需要提供**Harbor格式**，高校根据高校能力酌情提供Harbor还是非Harbor格式的原始文件

1. 知识体系

- 题目需要平均分布，以下一二级标签需要覆盖，如果需要补充二级标签也可以，需要提前说明。另外，目前的三级标签暂时为空，需要在出题的时候补足。题目出题需要分布均匀，不接受2道（2道本身可以）以上的题目是一个三级标签。

	A	B	C	D	E
1	领域	所属领域二级标签			
2	通用办公	T1-信息获取与知识综合			
3		T2-数据处理与分析			
4		T3-建模与决策支持			
5		T4-内容生产与表达			
6		T5-规划与任务协调			
7		T6-沟通与协同			
8		T7-审阅与质量治理			
9		T8-系统执行与流程流转			
10	金融	Fin1-投资银行			
11		Fin2-股票研究			
12		Fin3-私募股权			
13		Fin4-财富管理			
14		Fin5-零售证券投资			
15		Fin6-家庭财富规划			
16		Fin7-消费金融			
17		Fin8-个人税务与社保			
18		Fin9-跨境个人金融			
19	法律	Law1-诉讼律师			
20		Law2-非诉律师			
21		Law3-企业法务与合规			
22		Law4-法官与法院辅助			
23		Law5-检察官与检察辅助			
24		Law6-立法与政策研究			
25	医疗	Med1-患者服务			
26		Med2-科研与学术			
27		Med3-教学与人才培养			
28		Med4-医疗质量管理			
29		Med5-医院管理			

1. 难度分级

- 按照任务的**三模型平均正确率**，划分为易、中、难。
- **三模型平均正确率**：核心评价指标，选择模型A、B、C作为待测模型，取其产物经由打分文件打分后的平均分。

级别	产量占比	平均正确率
A1易	20%	<70%

A2中	60%	<60%
A3难	20%	<50%

- 单条：Claude code框架下，跑 gpt-5.6-sol、claude-opus-4-8、qwen3.8-max0902三个模型，。所有题目满分归一化为 1.0 的情况下，对于GPT-5.6 sol / Opus 4.8 / Qwen3.8-max 0902 三个模型，裁判模型为qwen3.7 plus，每种模型都跑1次求平均分，均分需要 < 0.7 ；且至少有一个模型有得分（避免全 0 的"死题"）。

跑分产物及轨迹要求：在提交题目文件时，请同步提供模型产物和跑分轨迹，用于验证难度要求。

1. 三个核心组成

1.1 任务描述

- 自然语言描述任务场景、需要用到的材料、交付物要求。
- 包括任务说明，产出要求，硬约束（禁止项、文件名要求）必须用独立段落显式写出，不得隐藏在括号内。

1.2 参考文件

- 完成该任务/作业所需的真实输入（如 CSV、PDF、合同、日志）。
- 该任务场景下真实的交付物是什么，就用什么源文件。
- 必须为真实数据；不得要求模型凭空猜测法规条款、政策口径、职责分工或统计数据。
- 数量没有限制，总大小在20GB以内。

1.3 参考答案

- 由领域专家产出的标准答案，作为打分项自检基准。
- 与题目标注中规定的交付物类型、文件名、数量严格一致。
- 参考答案中的文件经过打分项判分后须满足 $\text{score_final} \geq 0.85$ ；若 < 0.85 则不符合要求，需修正。

2. 打分项

- 打分项 = 一个得分点/扣分点，即考察交付物，
 - 符合某一条在实际生产中**被要求或有正向收益**的打分项，则得分；
 - 符合某一条实际生产中**应该杜绝或避免**的打分项，则扣分。

- **注意：不能在同一个打分角度上，既写得分点，又写失分点，造成双重得分或双重扣分。**
- 每条打分项，**描述一个具体的、可验证的评分标准**，包含以下字段：

2.1 任务描述description：具体的评判标准描述。

• 单条打分项要求

- **原子性**：每条打分项描述一个**独立、明确、可验证**的评分点，仅检查一个方面（避免一条捆绑多个独立事实/多个可接受值）。
- **准确无歧义**：表述完整、事实正确、依据可靠，使不同评分者能够形成一致理解。
- **可独立判断**：打分项应包含作出判断所需的关键信息，不要求评分者额外推导、补充标准或进行二次判断。
 - 不推荐：收入实现了明显增长。
 - 推荐：收入同比增长了 65%。
- **来源合理**：打分项必须来自以下内容，不能凭空增加“伪需求”：
 - 项目描述中的明确要求；
 - 参考文件中的明确要求；
 - 根据任务目标和使用场景可以合理推导出的隐含要求。
- **有明确判定锚点**：禁止使用“语言流畅”“结构清晰”“内容专业”等空洞描述，应明确说明可观察、可验证的表现。
 - 不推荐：PPT 排版美观。
 - 推荐：单页正文不超过 150 字，文本无明显遮挡、重叠或溢出。
- **客观可验证**：优先评价能够直接核查的事实、数据、结构和结果，避免直接使用“美观”“深入”“专业”等主观词语。确需评价主观质量时，必须将其转化为具体的可观察标准。
- **粒度合理**：既不要把多个独立要求合并为一项，也不要将一个完整动作拆成大量无实际意义的小项。
- **打分对象**：如果你的输出文件有多个，在打分项中明确给出本条的打分对象。

• 打分项之间的要求

- **互不重复、互不冲突**：不同打分项应评价不同内容，避免同一问题被重复计分，也不能出现判定标准相互矛盾的情况。
 - 例如，“公文是否专业、有条理且合规”应拆分为：
 - 文种选择是否正确；
 - 格式要素是否齐全，如标题、主送机关、正文、落款、发文字号等；
 - 请求事项是否明确，是否符合“一文一事”。
- **具有区分度**：正分项和负分项的判定边界应明确；type为gradient项的，正分项要求能区分“部分满足”和“完全满足”，避免不同表现获得相同评价。
- **整体覆盖完整**：所有打分项合起来应覆盖任务的主要目标和关键能力，并能够从不同维度评价交付物质量，不能遗漏关键要求。

- **权重体现重要性**：同一份打分文件中，应根据各打分项对任务结果的影响程度设置不同的 `weight`，避免所有打分项机械地使用相同权重。
- **允许设置合理亮点项**：可以评价项目要求之外、但基于常识会影响用户判断或交付质量的内容。此类要求应具有明确价值和合理依据，不能无限扩展任务范围。
- **判断结果稳定（鲁棒性）**：同一套打分项由不同 Judge 或在不同时间多次评分时，结果应基本一致。若评分结果波动较大，应进一步明确描述、判定边界和示例。

2.2 主客观类型 `criterion_type`:

- Objective = 可度量、可验证，仅凭回答本身即可作出明确判定；
- Subjective = 需要打分员的判断与语境解读（语气/质量/风格，或对某理由、断言、示例是否成立的判断）。
- 字段约束： `criterion_type` $\in$ {Objective, Subjective}。

2.3 显隐式类型 `criterion_necessity`:

- Explicit = 在 prompt 中逐字明文给出的要求；
- Implicit = 没有明说但从语境中必然推导出的要求。
- 字段约束： `criterion_necessity` $\in$ {Explicit, Implicit}。

2.4 权重 `weight`

- 分值（正分表示奖励，负分表示扣分/惩罚）。
- 不接受恶意负分、故意增加题目难度/降低分数的行为。
- 字段约束为 `weight` $\in$ {+10、+7、+3、-3、-7、-10}，不能取任何其他值。
- 分值按下表取值：

级别	分数	含义
Critically Important	+10	不满足就是"答错大题"，核心要素
Important	+7	明显增色，但不一定是最低标准
Slightly Important	+3	细节/锦上添花
Slightly Detrimental	-3	小错误、小跑题
Detrimental	-7	重要错误，但整体还能用


```
"dimension": "内容质量-数值与计算准确性",
"criterion_type": "Objective",
"criterion_necessity": "Explicit",
"type": "binary",
"weight": 3.0
}
```

2.6 评价维度dimension

每条 打分项 需要有其所属评分维度。下面定义了综合考虑的维度，主要是引导大家设计打分项的时候思考全面，不遗漏重大维度，并且能有策略专注在价值维度上挖掘打分项。维度根据任务的要求来动态调整，不同的任务需要有区分度。

- 根据下表给出 打分项 评价的一级维度和二级维度，二级维度可为空。
- 不同维度的权重设置要求
 - 内容质量、操作与交付安全应该总是较高weight
 - 对于ppt等设计类交付物，视觉美感与格式规范维度应该较高weight
 - 对于行业性比较突出的交付物，专业规范维度应该较高weight
 - 对于写作类交付物，结构与组织维度应该较高weight
 - 对于数学计算要求较高的交付物，比如金融场景，数值与计算准确性维度应该较高weight

一级维度	二级标签	主要检查什么	典型条目
指令遵循【必须】		检查 instruction 中显式要求的任务内容与交付约束是否被完整执行，包括范围限定、数量、命名、路径、格式、单位、精度以及明确要求包含或禁止的内容等。只检查 instruction 明确提出的要求；内容本身是否正确、专业、深入，归入对应内容质量维度	「结果文件名为 「存放在 output 留两位小数」→

内容质量【必须】	结论正确性	检查基于已有事实、数据和分析所形成的 最终判断、结论、推荐或决策是否正确 ，是否与证据一致，是否存在结论与数据相矛盾、判断方向错误或关键结论遗漏等问题。重点检查“最终得出了什么判断”，而非具体计算过程或论证深度。	数据显示 A 市场强度等关键指标，荐应为 A 市场，
	数值与计算准确性	检查数值提取、公式计算、统计口径、单位换算、聚合方式、分母选择、时间范围、精度及容差等是否正确	合计行 = 各月之换算正确
	专业规范	检查内容是否符合任务所属行业 / 领域的专业知识、规则、标准和通行实践，包括会计准则、法律规则、医学规范、行业标准、专业术语及业务口径等	「应收账款」按类；法律分析使非已失效规定；FCF 等指标使用径
	分析与论证质量	检查产出中的事实、数据和引用是否忠实于输入材料及可验证的客观事实，不无依据地编造、篡改或混淆信息；引用和来源是否真实可追溯；跨文件处理时是否正确区分主体、版本、时间和统计口径。既检查 workspace 内事实，也检查任务涉及的外部客观事实。	「A 公司于 2016 在 industry_r 实有该项内容，年成立的，溯源容，学术调研需求中题、作者、期刊为幻觉」
	事实忠实性	检查产出中的事实、数据和引用是否忠实于输入材料及可验证的客观事实，不无依据地编造、篡改或混淆信息；引用和来源是否真实可追溯；跨文件处理时是否正确区分主体、版本、时间和统计口径。既检查 workspace 内事实，也检查任务涉及的外部客观事实。	「A 公司于 2016 在 industry_r 实有该项内容，年成立的，溯源容，学术调研需求中题、作者、期刊为幻觉」

结构与组织		检查交付物的信息架构和组织方式是否合理，包括章节 / 页面结构是否完整、内容层级是否清晰、顺序是否符合逻辑、信息分组是否合理、关键模块是否缺失，以及文字、表格和图表是否放置在合理的上下文中	报告按「核心结论」形成清晰结论
操作与交付安全		检查 Agent 在执行过程中是否安全处理用户已有文件和 workspace。不得误删、覆盖、破坏无关源文件，不得因编辑或格式转换造成数据、公式、页面或其他原有内容意外丢失	处理完成后 <code>data</code> 覆盖或删除则命令
安全合规		检查产出内容及执行行为是否满足隐私、数据安全、版权、法律法规及业务合规要求，避免泄露敏感信息、违规使用内容或产生明显误导、偏见及其他可能造成实际风险的问题。	对外报告不得直白证号、手机号等
超预期贡献		其他要求都满足之后，进一步提升交付价值的部分	事实二次核对、呆设计、指出 <code>in</code> 更完善的交付物
视觉美感		交付物是否足够美观，比如排版、配色等内容是否让接手这份交付物的人感到欣赏，比较偏主观。（仅针对交付物有美观度要求的情况需要配置得分点，普通任务不建议包含）	PPT的配色和排版

2.7 打分项分布要求

- 打分项的分值设计应符合统一标准，能够真实反映各能力的重要程度。主要包括：
 - **领域锚点占比**：交付物内容质量维度（交付物内容质量下所有二级标签）锚点正分，占全部正分的 **30%** 以上，表示本题对专业性有很高的要求，非简单指令遵循就可满分，要求有极强的领域知识理解。
 - **关键项占比**：每题至少包含 2 条 Critically Important (+10) 评分项，模拟用户真实期望，给出最影响产物本身可用性的打分点。

- **-10分项**：仅用于重大专业错误、幻觉、业务安全、合规风险等真正影响答案可信度的情形，不得滥用。
- 一般来说，指令遵循、结论正确性、分析与论证质量与事实忠实性这些维度总是需要的。
 - 对于行业性比较突出的交付物，应该覆盖专业规范维度。
 - 对于ppt等设计类交付物，应该覆盖视觉美感与格式规范维度。
 - 对于写作类交付物，应该覆盖结构与组织维度。
 - 对于数学计算要求较高的交付物，比如金融场景，应该覆盖数值与计算准确性维度。

3. 元数据

- 领域、分级、难度、目标模型通过率预估、关键能力标签。

字段名称	题型	字段说明	是否必填
题目编号	-	系统自动生成	必填
所属领域	单选	通用办公/金融/医疗/法律，支持后续新增	必填
所属领域二级标签	单选	二级标签，参考3.知识体系	必填
所属领域三级标签	单选	自行填写	必填
所属领域四级标签	单选	自行填写，描述题目所属细分场景	必填
评测的能力	填空	该任务能评测的具体专业能力	必填
难度等级	单选	A1-A3	必填
任务说明	填空	为什么选择这个任务，真实性如何保障，真实场景中的交付物是什么	必填
所需工具	填空	完成任务所需办公工具/数据库 (Word/Excel/PPT 等)	必填
领域知识依赖	填空	完成任务所需的专业知识说明	选填

是否依赖VL	单选	VL即视觉-语言能力 是/否	
--------	----	-------------------	--

4. 得分计算

• 单题计分公式：
$$\text{Score} = \frac{\sum_{i \in P} s_i \cdot w_i + \sum_{j \in N} h_j \cdot w_j}{\sum_{i \in P} w_i}$$

$w_i > 0$ ($i \in P$), P 正打分项; $w_j < 0$ ($j \in N$), N 负打分项

◦ $s_{\text{正}i} = \begin{cases} 1 & \text{binary 正打分项命中} \\ \{0, 0.25, 0.5, 0.75, 1\} & \text{gradient 正打分项实际档位} \end{cases}$

$h_{\text{负}j} = \begin{cases} 1 & \text{binary 负打分项命中} \\ \{0, 0.25, 0.5, 0.75, 1\} & \text{gradient 负打分项实际档位} \end{cases}$

- 三模型平均分：(score1+score2+score3)/3。

5. AI机检&&人工质检标准

- AI质检题目质量
- 人工质检题目质量SOP
- 打分项生成
- AI质检打分项质量
- AI总分检查：
 - 参考答案得分>0.85 && 三模型平均分 < 0.7
 - 不同等级的平均分符合该等级要求, A1<0.7, A2<0.6, A3<0.5
 - 至少有一个模型得分
- 质检SOP: [RL 0-1标注数据质检Guideline](#)