

20260913外发版-基于weakness和skill 的数据构造方案

注意：需要和“外发版-评测题包交付规范（rewardkit）20262913”组合使用。

1. 项目背景与使用范围

- 本文件定义该RL从0到1标注生产下数据的规格、格式、质量标准与验收流程。
- 适用对象：提供标注数据的所有数据生产流程。
- 面向对象：供应商、内外部专家、标注质检平台。
- 写给领域专家：
 - 作为对应办公场景的专家，你熟悉该领域的任务要求，熟悉该领域办公目标实现的产物标准。
 - 你的工作是根据自己擅长的领域，选择合适难度的任务，给出能对应办公场景、具备真实业务价值的**任务描述**，并且给出恰当的**参考文件**，以及对应该任务的**参考答案**。同时你需要针对该任务，给出一套能衡量任务做得好坏的**打分项**。
 - 我们会根据你给的打分项
 - ① 对你提交的参考答案打分，看得分是否足够高（正确率>0.85）；
 - ② 用3个模型执行你给出的任务，并用你给出的打分项打分，看难度是否足够高。
 - 此外，人工质检会重点考察题目真实性、参考答案合理性、打分项设计合理性、是否hack等异常作弊情况，一经发现，直接打回。

2. 难度分级

- 按三模型平均正确率划分难度：只要平均分低于 70% 即算难度达标；达标后再按下表归入 A1 基础 / A2 进阶 / A3 高难三档（区间不重叠）。
- 三模型平均正确率：
 - 单条：Claude code框架下，跑 gpt-5.6-sol、claude-opus-4-8、qwen3.8-max0902三个模型，。所有题目满分归一化为 1.0 的情况下，对于GPT-5.6 sol / Opus 4.8 / Qwen3.8-max 0902 三个模型，裁判模型为qwen3.7 plus，每种模型都跑1次求平均分，均分需要 < 0.7；且至少有一个模型有得分（避免全 0 的"死题"）。

难度分级定义

级别	产量占比	数量	平均正确率
----	------	----	-------

A1 基础	20%	200（单个领域50题）	60%≤得分<70%
A2 进阶	60%	600（单个领域150题）	50%≤得分<60%
A3 高难	20%	200（单个领域50题）	得分<50%

首批构造的数据需要覆盖2个方面：

领域覆盖：通用办公GO、金融FIN、法律LAW、医疗MED、数据分析DA、游戏GA、设计DE，数据需要平均覆盖不同领域，同时不同领域下的数据应该均匀分布，不接受一个知识点/workflow出题大于等于3道。且数据分布符合后文专项数据和weakness数据的要求。

数据总量：2000条（基于skill/tool/workflow等内容专项数据1000条，weakness数据1000条）

跑分产物及轨迹要求：在提交题目文件时，请同步提供模型产物和跑分轨迹，用于验证难度要求。

一、专项数据：基于skill/tool/workflow等内容专项数据

更关注某一能力方向的系统性和完整覆盖，例如 Tools / Skills / Workflow 专项需要从能力维度出发，尽可能全面覆盖不同场景、难度、环境和任务形态，目标是整体提升该能力

一级	二级	数量
Skills 数据	Skill Discovery	200
	Skill Generation / Editing	200
	Skill Dependency	200
Workflow Execution	Dependency-aware Workflow	200
	Subagent Workflow	200

二、Weakness-driven 数据：

需要更聚焦已经观察到的具体模型缺陷，从明确的 Bad Pattern / Trigger 出发，针对性构造能够稳定复现并训练该问题的场景。

数量：1000条，要求覆盖14种weakness，以及数据复杂性覆盖C1-C5

- 数据需要在元数据中标注数据主要作用于哪个weakness，必须覆盖1个以上weakness。
- 1000 条数据须覆盖全部 14 种 weakness。计数规则：每条数据在 weakness_tag 中标注 ≥ 1 个；一条数据标注多个时，对其标注的每一种各计 1 次覆盖。每种 weakness 至少被 50 条数据覆盖，且不超过 250 条。标注须与题目实际埋入的 trigger 一一对应：标了某个 weakness，题面和 environment 中必须存在能稳定诱发该 weakness 的设计点。
- C1-C5 分级参考如下

等级	文件数	Requirement 数/约束	输出产物数（与文件数不绑定，主要做参考，核心是需要复杂任务的任务）	Evidence Chain	执行步数 / 子任务数	工具种类数	领域专业深度（参考）	题量	占比
C1	2	3	1-2	1-hop	1-3 / 1	1	通用常识	120	12%
C2	5	6	2-3	2-hop	4-7 / 2-3	2	基础专业	250	25%
C3	10	10	3-4	3-hop	8-15 / 4-6	3	中级业务	350	35%
C4	25	15	4-6	4-hop	16-30 / 7-10	4	高级专业	180	18%
C5	50+	20	4-8（如果是一个大型项目，如做整个法律尽职调查，产出物页可以为1份。）	5-hop	30+ / 10+	5+	专家级	100	10%

各等级画像与典型场景

等级	画像	典型真实生产力场景
C1	单文件、单输出、单步完成，无需专业知识	从一份 Excel 中统计销售额并生成一句话结论
C2	多文件简单对照，2 种工具，基础专业门槛	对比两份报价单，输出差异表 + 推荐方案
C3	标准项目规模，中等推理链，3 种能力组合	根据销售数据、客户反馈、产品资料生成分析报告 + 图表 + 建议清单
C4	复杂项目级任务，长依赖链，需要高级领域知识	基于季度财报、行业研报、内部纪要撰写投资 memo + 财务模型 + 风险清单
C5	大型项目/知识库，多产物完整交付，专家级判断	完成并购项目的 CIM 分析、估值模型、尽调问题清单

指标说明

维度	含义	计量方式
文件数	模型可读取/处理的输入文件数量	不含重复文件、临时文件
Requirement 数	显式或隐式需满足的条件/约束条数	含功能、格式、引用、质量约束
输出产物数	最终需交付的文件/片段/结果数量	如代码文件、表格、报告段落、邮件等
Evidence chain 深度	完成答案所需的最长跨文件推理步数	1-hop = 单文件直接可得
执行步数	模型需调用的原子操作/工具调用次数	工具调用次数
工具种类数	指不同类型的能力/工具，如：文本阅读、搜索、代码执行、计算、写作、绘图、表格处理等。同一类工具的多次调用只算 1 种。	工具种类数量

Weakness-driven 数据构造方案：

- 数据需要在元数据中标注数据主要作用于哪个weakness，必须覆盖1个以上weakness

- weakness_tag为b列

优先级	Weakness	典型行为	具体case	推荐的数据构造方式
W1	长文档下的硬约束遵循较差	模型不是完全没看到要求，而是随着内容生成变长，部分 hard constraint 从 working state 中丢失；尤其是需要真实 artifact operation 才能满足的约束，例如 section break、页码域、字数上限、公式保留，而不是在正文中“写到了”就算完成。	PA-T1-001 无人驾驶航空器管理办法起草：明确要求正文 4000–8000 字，Qwen 最终约 14825 字，接近上限两倍；同时页码域、单双页等要求并未真正写入 Word XML(work360)	构造 long-form + 5–15 个 artifact-level hard constraints 的任务。重点混合三类约束：内容约束、数量约束、真实文件结构约束。

W2	关键冲突 下自行选 边 / 修改 输入，而 不是模糊 澄清或是 说明具体 冲突情况	Workspace / Context 中存在互 相矛盾的关键信 息，模型甚至已经 发现冲突，但会自 行选择其中一个版 本继续，极端情况 下直接“修正”输 入。报告中血钾 8.2 mmol/L vs “持续低钾”、材 料用量 100ml vs 120ml 都稳定复现 了该问题。	医疗冲突 Case： 病例文字明确描 述“持续低钾”， 但化验结果显示 $K^+=6.2$ mmol/L。 高钾和低钾对应 完全不同的诊断 和治疗策略，模 型不能自行决定 哪一条是真的； 报告观察到模型 面对这类冲突会 直接选一个版本 甚至修改输入后 继续(humanlaya)	构造含冲突 Workspace 的任务。同 一事实分别 出现在 Excel / PDF / 邮件 / Markdown / 数据库结果 中，两个值 对应完全不 同的最终答 案；真正值 只能通过询 问用户或额 外可信工具 确认或是有 其他证据 (这里可以 是静态user 多轮数据)
----	--	--	---	--

W3	阻塞状态的识别与恢复能力较差	模型在任务执行过程中遇到关键资源缺失、权限受限、外部依赖失败、输入损坏或必要信息不足等 Blocking State 时，无法稳定判断 典型错误主要有两类： 过早放弃 / 不懂变通：原路径失败后直接停下或把任务推回用户，明明存在 retry、替代工具、备用数据源等可恢复路径； 强行闭环 / 伪完成：关键阻塞尚未解除，却使用假数据、placeholder、自行估值、未经授权的替代方案继续执行，并最终宣称任务完成	case1: image工具不可用，但是模型一直仍在反复调用； case2: 某相关文件不存在，模型一直在反复寻找该文件直到超长	主要是教会模型 Blocking State → Recovery 可以涵盖多种类型： 某数据不可用(目标文件名不可用，但 Workspace 中存在合理替代文件) 某服务不可用 -> 需要模型自行先修复服务 原路径不可行，但环境里有另一种工具可以完成 缺少关键信息 -> 需要 ask_user
----	-----------------------	--	--	--

W4	多要求 / 多交付物 下缺少 Requirement Coverage Accounting	简单任务基本能完成，但当显式要求项、文件数、sheet / section / field / edit item 增多时，模型容易“完成大方向但漏细项”，缺少一套持续维护的 requirement checklist	hard_194: PPT 要求完成 10 项修改，Qwen 约只完成 4/10； hard_008: 要求同时交付完整 Excel 审计表和 Word 摘要但缺少必需工作表 / 章节；hard_180: 7 页脚本 PPT 漏掉每日时段和逐镜来源。	构造要求有多个产物要求的复杂任务
W5	关键信息缺失时“该问不问”	模型能够意识到部分信息缺失，却没有稳定转化成真正的“提问—等待”。目前分析到的漏问 case 中既有“声明关键假设但继续做”，也有直接静默补全。	通用-003 9 天 差旅穿搭：用户列出了衣物、帽子、围巾，却没有提供任何鞋款；任务又明确要求每天必须搭配一双鞋，且连衣裙必须配皮鞋。Qwen 没有询问可用鞋款，直接继续生成，最终鞋子部分缺失 (humanlaya)	刻意删除一个决定最终结果的 blocking variable。例如穿搭缺鞋款、金融测算缺收购比例、分析任务缺时间范围、PPT 缺目标受众等。

W6	用户补充信息后只局部更新，没有 Global Re-planning	模型“问到了、听懂了、写进答案了”，但依赖这一事实的其他规则、计算、排序、结论仍沿用旧值。 Qwen 在完整利用澄清信息的 case 中，仍有 59% 内容未满分、33% 有严重错误。	并购 Earn-out Case：模型能够主动追问并获得“首期收购 60%、剩余 40% 按业绩分期收购”等关键信息，但最终一方面把剩余 40% 当作购买日或有对价计入合并成本，相当于按 100% 收购； (humanlaya)	一个新增事实同时影响 3-5 个 downstream fields。例如主体从 A 改成 B，同时改变税率、适用法规、现金流计算、风险评级和最终建议。
W7	长表格 / 多 Sheet 下的数据覆盖与抗干扰能力弱	阅读长 Excel、多子表或重复实体时容易漏行漏对象、错误聚合、把 inactive / 非目标对象混入统计；模型有时已经注意到“同名多记录”等异常，但仍快速选择一个未经验证的处理口径	hard_155：没有提取 60 个子表数据； medium_050：源表存在同名学生多条考试记录，Qwen 将记录直接求和排名，得到无法回源的分数与前三名；另有 case 出现 inactive 对象、冲突项覆盖不足。	构造 row / sheet scaling + distractor injection：增加 sheet 数、行数、重复 key、inactive 记录、跨期记录、相似实体、隐藏列、异常值；让 gold 明确依赖正确的 grouping / filtering / dedup 规则

W8	启动 Subagent 后把“已派发”当成“已完成”	Qwen 可以正确拆分任务并启动多个研究 Agent，但多次在异步结果返回前直接结束主任务，没有等结果回收动作	H-104967 白银供给、回收率与回收技术综合研究：3 次 rollout 均启动 5 个研究 Agent，但全部停在“等待返回”	构造 需要依赖多个 delayed subagent result 才能完成 final 的任务。各子 Agent 分别掌握不可替代的一部分信息。（该类任务也是我们目前非常缺少的）
W9	Skill 被形式化调用，但没有真正改变关键判断	报告发现“使用了匹配且关键的 Skill”并不等于结果改善。模型可能完整走了一遍 Skill checklist，却没有根据检查结果修正原结论。	Clinical Skill Case: Qwen 先搜索 Skill，再激活 clinical-diagnostic-reasoning 并读取 clinical-reports; Skill 确实使输出结构更完整，也加入了偏差检查，但模型随后仍自行加入固定冰冻分流、固定切缘、固定药物线序等过度具体建议，说明 Skill 被“读了”，却没有真正约束每条建议的证据强度	构造一批必须依赖 Skill 中特有信息或行为规则才能正确完成任务，避免 Skill 只是“可有可无”的辅助材料。例如 Skill 明确要求发现数据冲突必须暂停，task 中刚好埋冲突。

W10	大 Workspac e 下缺少 Coverage Accountin g，读了一 部分材料 就开始形 成完整结 论	面对大量文件时， 模型没有维护“哪 些证据已看 / 哪些 未看 / 哪些章节依 赖哪些文件”的 coverage state， 而是在局部证据足 以形成一个看似合 理框架后提前开始 写结果，导致未读 取区域对应的事实 与风险系统性遗 漏。	L5-05 IPO 法律 尽调：要求基于 183 份底稿完成 法律尽职调查。 Qwen 实际只读 取 44 份，随后已 经开始形成完整 报告，最终触发 25 条披露完整性 扣分，股东持 股、知识产权、 劳动用工等整章 节缺失	构造 有几百 or上千个文 件的大 Workspace 任务，把不 同必答项的 关键证据分 散在不同文 件簇中。 可以进一步 构造“高信息 密度少文件” 和“信息稀疏 多文件”的任 务，训练模 型做有效 coverage planning， 而不是无脑 全读
W11	无据自造 数据与口 径	自行设定界值、外 推假设、套用惯例 公式、沿用旧版方 案或引入工作包外 参数，把没有来源 的数字写进结论， 甚至声称「指南明 确写明」。	自设数值界值却 称指南「明确写 明」；另一例针 对「物理核数→ 云端 vCPU 如何 对应」的唯一检 索 exit 1 后未追 查，直接用自拟 口径逐台匹配	规范文件里 故意不含某 个常用阈 值，正解是 如实存疑而 非套惯例； 另设一处规 范中确有明 文条款，考 察是否真去 查；提供两 套口径的中 间数据，考 察是否标注 口径而非混 用

W12	跨源交叉 核对缺失	只凭单一字段、单 一线索或单份材料 下判定，不与其他 数据源互证；自算 值单向否定源文件 登记值而不回到规 则条文双向核实。	同一份查询结果 中已同时出现 B_ECOM 93.2% 的部门有效口 径，仍以整池 71% 定调「有余 量」；另一例 171 笔逐笔勾对 仅命中 1 笔仍不 修正匹配逻辑	同一事实分 散在 ≥ 3 份 材料且口径 不同（如整 池口径 vs 部 门口径）； 题面要求交 叉核对并说 明口径取舍 理由；设计 一处自算值 与登记值冲 突，正解是 回查规则条 文
W13	规划与策 略调整失 当	缺少任务拆解；在 同一处失败上反复 重试、重复调用； 一次成稿不做迭 代；耗在表面排版 而内容不再复查。	对手册检索返回 的全是模板化噪 声条款，未改换 关键词也未改查 银行流水/科目导 出，直接转入定 稿，使租赁、薪 酬、水电等费用 行缺少交叉印证	长程多子任 务（ ≥ 6 个交 付要件）， 需显式拆解 才能不漏； 埋一个必须 换策略（而 非重试）才 能通过的死 路；要求交 付含任务拆 解与完成状 态表

W14	脱敏与合规疏漏	含真实姓名或敏感内容的版本直接落盘进交付目录；脱敏自检报警未处理即定稿。反向地，也包括过度脱敏删掉了用于对照的核验证据。	脱敏扫描已标出「身份证」字样与精确到日的日期仍存在，仍宣称「已用正则扫描确认无残留直接标识」；另一例未脱敏版本（含 '孙浩'、'RA-207'）直接落到交付路径	材料含可识别标识（姓名/身份证/内部编号），题面给出明确脱敏规则并列明「必须保留」的对照项；要求首版必须写在 /tmp，脱敏后才可进交付目录
-----	---------	--	--	--

粘贴表格（和上面的一样）

	A	B	C	
1	优先级	Weakness	典型行为	
2	W1	长文档下的硬约束遵循较差	模型不是完全没看到要求，而是随着内容生成变长，部分 hard constraint 从 working state 中丢失；尤其是需要真实 artifact operation 才能满足的约束，例如 section break、页码域、字数上限、公式保留，而不是在正文中“写到了”就算完成。	PA-T1-001 5字，Qwen 最终
3	W2	关键冲突下自行选边 / 修改输入，而不是模糊澄清或是说明具体冲突情况	Workspace / Context 中存在互相矛盾的关键信息，模型甚至已经发现冲突，但会自行选择其中一个版本继续，极端情况下直接“修正”输入。报告中血钾 8.2 mmol/L vs “持续低钾”、材料用量 100ml vs 120ml 都稳定复现了该问题。	医疗冲突 Case mmol/L。高钾；定哪一条是真的
4	W3	阻塞状态的识别与恢复能力较差	模型在任务执行过程中遇到关键资源缺失、权限受限、外部依赖失败、输入损坏或必要信息不足等 Blocking State 时，无法稳定判断 典型错误主要有两类： 过早放弃 / 不懂变通：原路径失败后直接停下或把任务推回用户，明明存在 retry、替代工具、备用数据源等可恢复路径； 强行闭环 / 伪完成：关键阻塞尚未解除，却使用假数据、placeholder、自行估值、未经授权的替代方案继续执行，并最终宣称任务完成	case1 : case2: 某相
5	W4	多要求 / 多交付物下缺少	简单任务基本能完成，但当显式要求项、文件数、sheet / section / field /	hard_194 : PPT 要求同时交付

Qwen 在要求项更多、交付物更多、跨应用更多的 hard query 上，思考和工具调用没有随难度增加，甚至有所下降，明显弱于其他模型；而 Opus 会相应增加执行与验收投入。这个现象更适合作为所有定向 weakness 数据的 difficulty-control 维度。

基于skills/workflow的scaling的专项数据

1. 背景 & 出发点

目前 Cowork RL 数据中，大部分任务仍运行在相对简单的环境中：

- 以 filesystem / shell / 少量原生工具为主；
- Tool schema、可用能力和调用方式相对固定；
- Skill 即使存在，也经常只是辅助信息，并非完成任务所必需；
- Workflow 多数是线性的「读取 → 处理 → 输出」，较少包含真实业务中的状态变化、异步依赖、异常恢复、跨工具协同等复杂过程。

下一阶段希望数据建设从单纯扩充 Task Distribution，进一步转向扩充 Environment Distribution。

2. 整体数据目标

本专项主要覆盖以下几类能力：

Skill Dependency

任务必须真正依赖 Skill 中的特有信息、规则或 SOP 才能稳定完成。

skill能够包含一些特有信息或行为规则，避免 Skill 成为一个可有可无的 contextual document

Workflow Execution

构造真实存在：多步骤依赖；多工具协同；branch；async；blocking state；subagent；的长链路任务。（最好是有涉及subagent的，例如在codex下运行该任务会触发subagent）

MCP Scaling（低优）

扩大模型在非原生工具、陌生 Tool Schema 和不同 Tool 组合下的泛化能力。可主要通过 MCP

数据需要基于各 Agent Framework 可接入的 Plugin / MCP 能力构造任务，并在每条任务中明确提供当前 Environment 下模型可使用的工具集合 / MCP。工具可以是框架已有能力，也可以是动态注入的自定义工具（在题目里显式说明）。

3. Skills 数据需求

Skill Discovery

提供多个 Skill, 要求模型自行判断: 是否需要 Skill, 以及应该使用哪个 Skill。

Skill Dependency

构造:

没有 Skill 中的特殊知识 / 行为规则, 模型很难正确完成任务。

推荐构造方式

类型一: 特殊业务规则

Skill 明确规定: 当两个 authoritative source 的关键字段冲突时, 禁止自行选择, 必须暂停并向用户确认。

Task 中主动埋入这种冲突。模型如果没有真正遵循 Skill: 最终一定会进入错误 branch。

类型二: 环境特化 SOP

例如 Skill 定义某企业内部审批流程: `Draft → Compliance Review → Manager Approval → Publish`

Task 要求完成发布。如果模型直接: `Draft → Publish`。最终 Workflow State 必须失败。

类型三: 特殊计算 / 判定规则

Skill 中包含: 特殊阈值; 内部映射规则; 自定义字段定义; 业务优先级; fallback 顺序。要求这些内容直接影响 final answer。

Skill Generation / Editing

可以增加一批：创建 Skill；修改已有 Skill；从 SOP 抽取 Skill；Skill migration；Skill package repair之类的任务

4. Workflow 数据需求

Dependency-aware Workflow

任务中存在明确 dependency：

```
A → B
A → C
B + C → D
D → Final
```

要求模型：

- 正确拆解 dependency；
 - 维护哪些任务已完成；
 - 避免提前执行依赖未满足的步骤；
 - Final 前确认 dependency 已全部完成。
-

Subagent Workflow

构造必须依赖多个 Subagent Result 才能完成 Final 的任务。

数据交付 Metadata

建议每条数据额外维护以下字段：

```
skill_set          = ["approval-workflow"]    # 环境内安装的功能型 skill (=
environment/skills/ 下的目录名)
task_complexity     = "C3"                    # C1-C5，取值口径见正文分级表
expected_skill_dependencies= ["approval-workflow"] # 完成任务真正必须依赖的
skill (子集，可为空表示 Skill Discovery 干扰项)
weakness_tag        = ["W07-流程跳步", "W12-约束遵循"] # 覆盖≥1个
```

[复制代码](#)

```
skill_set = ["approval-workflow"] # 环境内安装的功能型 skill (= environment/skills/ 下的目录名)
task_complexity = "C3" # C1-C5, 取值口径见正文分级表
expected_skill_dependencies= ["approval-workflow"] # 完成任务真正必须依赖的 skill (子集, 可为空表示 Skill Discovery 干扰项)
weakness_tag = ["W07-流程跳步", "W12-约束遵循"] # 覆盖≥1个
```

字段	类型	取值写法 / 约束
<code>skill_set</code>	array	环境内安装的功能型 skill 目录名, 须与 <code>environment/skills/<name>/</code> 逐一对应; 可含干扰项 (Skill Discovery 场景)
<code>task_complexity</code>	enum	C1 - C5, 按正文分级表的文件数/requirement/evidence-hop 等硬指标判定
<code>expected_skill_dependencies</code>	array	<code>skill_set</code> 的子集: 不依赖它任务必失败的 skill。Skill Discovery 任务里这一项应严格小于 <code>skill_set</code> (存在故意的无关 skill)
<code>weakness_tag</code>	array	覆盖 ≥1 个;

本专项构造的数据需要遵循以下完整task.toml参考:

```
schema_version = "1.4" # 照抄
```

格式: /app/output/{你的交付物名称}

```
artifacts = [
  "/app/output/FIN-T2-001_财务分析报告.xlsx",
  "/app/output/FIN-T2-001_毛利率趋势.png",
  "/logs/artifacts/output",
]
```

```
[task]
```

```
name = "work/fin1-001" # 任务名称
```

```
version = "1.0.0" # 任务版本
```

```
description = "基于两期年报与交易流水产出财务分析报告" # 任务描述
```

```

[metadata]
task_id = "FIN1-skill-DEP-001" # 题目编号
author_organization = "<供应商名>"
category = "skill-dependency"
domain = "金融" # 所属领域：通用办公/金融/医疗/法律
domain_l2 = "投资银行" # 所属领域二级标签（对齐知识体系表）
capabilities = "财务比率计算、估值口径" # 评测的能力：该任务能评测的具体专业能力
difficulty = "A2" # 难度等级：A1易/A2中/A3难
vl_dependency = "否" # 是否依赖VL（视觉-语言能力）：是/否
source_note = "任务来源、真实性保障、真实场景中的交付物是什么" # 任务说明
tools = "Excel/Python" # 所需工具（办公工具/数据库，Word/Excel/PPT 等）
domain_knowledge = "再融资定增的财务分析口径与可比公司估值方法" # 领域知识依赖（选填）
task_complexity = "C2" #取值C1-C5
weakness_tag = ["W07-流程跳步", "W12-约束遵循"] # 覆盖≥1个，按算法词表填写，至少一项
environment_template = "<平台已确认的环境模板名>"
tool_set = ["filesystem", "shell", "python"] # 按实际可用能力填写
☐ # 本示例未提供技能；有技能时填写目录名
expected_tool_dependencies = ["filesystem", "shell", "python"] # 按实际必要能力填写
☐ # 必须是 skill_set 的子集
tags = ["finance", "office", "A2", "skill-dependency", "sop-enforcement", "workflow", "docx", "llm-judge"]

```

逐题填写任务关键词

```

[[metadata.deliverables]] # 交付物一
path = "FIN-T2-001_财务分析报告.xlsx" # 交付物一的路径
required = true
desc = "主交付物：财务分析报告" # 交付物一的描述
[[metadata.deliverables]] # 见交付物一的说明，如有多个交付物，必须依次写明
path = "FIN-T2-001_毛利率趋势.png"
required = true
desc = "毛利率趋势折线图"
[agent]
timeout_sec = 72000.0 # 缺省 72000；
[verifier]
timeout_sec = 18000.0
user = "root"
[verifier.env]

```

Judge 相关变量统一 JUDGE_ 前缀，只写在 [verifier.env]、严禁写入 [environment.env]。

```

必选项（运行环境注入，AP 必给）；可选项一律用 ${VAR:-默认值} 语法给默认值。
JUDGE_API_KEY = "${JUDGE_API_KEY:-}" # 必选：judge 网关 key
JUDGE_BASE_URL = "${JUDGE_BASE_URL:-}" # 必选：judge 网关地址（可带 /v1,
test.sh 负责剥）
JUDGE_MODEL = "${JUDGE_MODEL:-qwen3.7-plus}" # 可选：裁判模型（经
REWARDKIT_MODEL 运行时生效）
JUDGE_PROVIDER = "${JUDGE_PROVIDER:-anthropic}" # 可选：信息性声明
JUDGE_API_PROTOCOL = "${JUDGE_API_PROTOCOL:-anthropic}" # 可选：openai 时
降级为 LLM judge（见 test.sh）
兼容旧环境的兜底注入
EVAL_API_KEY = "${EVAL_API_KEY:-}"
EVAL_API_BASE = "${EVAL_API_BASE:-}"
LITELLM_DROP_PARAMS = "true"
[environment]
os = "linux"
build_timeout_sec = 18000.0
network_mode = "public" # claude-code 框架下不要写 no-network（见 3.2 警示）
cpus = 2
memory_mb = 8192
storage_mb = 30720 # 照抄

```

> task.toml

 复制代码

Skill形态说明

- 当前可以主要通过写入到skills文件夹下的形式

功能型Skill的标准目录结构

```

AQ-002/
├── task.toml           # 任务声明
├── instruction.md       # 显式说明"通过 contract-redliner skill 完成，禁止其它
方式改文档"
├── environment/
│   ├── Dockerfile      # COPY skills/ /skills/ ← skill 在这里被装进环境
│   ├── skills/
│   │   └── contract-redliner/
│   │       └── SKILL.md # Anthropic Skill 格式：
frontmatter(name/description/compatibility)+正文SOP
│   │       └── scripts/ # read_document.py / propose_edits.py /
add_comment.py ...

```



```
every edit must be a real tracked change applied via the bundled scripts, never by
rewriting the file.
compatibility: Requires Python 3.10+ with python-docx==1.2.0, docx-revisions, lxml.
---
#Contract Redliner
（正文：分步 SOP、脚本用法、失败恢复、"绝不能用别的方式改文档"的硬规则——
这些"特有行为规则/阈值/映射"就是让 Skill 不可省略的关键
```



复制代码

```
---
name: contract-redliner
description: Redline Word (.docx) contracts with native tracked changes
and margin comments ... Use when asked to redline, mark up, revise a
.docx legal document – every edit must be a real tracked change applied
via the bundled scripts, never by rewriting the file.
compatibility: Requires Python 3.10+ with python-docx==1.2.0, docx-
revisions, lxml.
---

# Contract Redliner
（正文：分步 SOP、脚本用法、失败恢复、"绝不能用别的方式改文档"的硬规则——
这些"特有行为规则/阈值/映射"就是让 Skill 不可省略的关键
```

注意 [instruction.md](#) 里需要显式强调下要使用该skill：

```
Every edit and every comment goes through the contract-redliner skill installed in this
environment — never write [ADD:...] / [DELETE:...] markup, and never modify the
document by any other means.
```

task.toml参考

```
schema_version = "1.4" # 照抄

# 格式：/app/output/{你的交付物名称}
artifacts = [
  "/app/output/FIN-T2-001_财务分析报告.xlsx",
  "/app/output/FIN-T2-001_毛利率趋势.png",
  "/logs/artifacts/output",
]

[task]
name = "work/fin1-001" # 任务名称
version = "1.0.0" # 任务版本
description = "基于两期年报与交易流水产出财务分析报告" # 任务描述
```

```

[metadata]
task_id = "FIN1-skill-DEP-001"          # 题目编号
author_organization = "<供应商名>"
category = "skill-dependency"
domain = "金融"                        # 所属领域：通用办公/金融/医疗/法律
domain_l2 = "投资银行"                 # 所属领域二级标签（对齐知识体系表）
capabilities = "财务比率计算、估值口径" # 评测的能力：该任务能评测的具体专业能力
difficulty = "A2"                      # 难度等级：A1易/A2中/A3难
vl_dependency = "否"                   # 是否依赖VL（视觉-语言能力）：是/否
source_note = "任务来源、真实性保障、真实场景中的交付物是什么" # 任务说明
tools = "Excel/Python"                 # 所需工具（办公工具/数据库，Word/Excel/PPT 等）
domain_knowledge = "再融资定增的财务分析口径与可比公司估值方法" # 领域知识依赖
                                         （选填）
task_complexity = "C2"                  #取值C1-C5
weakness_tag = ["W07-流程跳步", "W12-约束遵循"] # 覆盖≥1个，按算法词表填写，至少一项
environment_template = "<平台已确认的环境模板名>"
tool_set = ["filesystem", "shell", "python"] # 按实际可用能力填写
skill_set = []                          # 本示例未提供技能；有技能时填写目录名
expected_tool_dependencies = ["filesystem", "shell", "python"] # 按实际必要能力填写
expected_skill_dependencies = []         # 必须是 skill_set 的子集
tags = ["finance", "office", "A2", "skill-dependency", "sop-enforcement", "workflow",
"docx", "llm-judge"]
# 逐题填写任务关键词

[[metadata.deliverables]] # 交付物一
path = "FIN-T2-001_财务分析报告.xlsx" # 交付物一的路径
required = true
desc = "主交付物：财务分析报告"      # 交付物一的描述

[[metadata.deliverables]] # 见交付物一的说明，如有多个交付物，必须依次写明
path = "FIN-T2-001_毛利率趋势.png"
required = true
desc = "毛利率趋势折线图"

[agent]
timeout_sec = 72000.0      # 缺省 72000；

[verifier]
timeout_sec = 18000.0

```

```
user = "root"
```

```
[verifier.env]
```

```
# Judge 相关变量统一 JUDGE_ 前缀，只写在 [verifier.env]、严禁写入
```

```
[environment.env]。
```

```
# 必选项（运行环境注入，AP 必给）；可选项一律用 ${VAR:-默认值} 语法给默认值。
```

```
JUDGE_API_KEY = "${JUDGE_API_KEY:-}" # 必选：judge 网关 key
```

```
JUDGE_BASE_URL = "${JUDGE_BASE_URL:-}" # 必选：judge 网关地址（可带  
/v1，test.sh 负责剥）
```

```
JUDGE_MODEL = "${JUDGE_MODEL:-qwen3.7-plus}" # 可选：裁判模型（经  
REWARDKIT_MODEL 运行时生效）
```

```
JUDGE_PROVIDER = "${JUDGE_PROVIDER:-anthropic}" # 可选：信息性声明
```

```
JUDGE_API_PROTOCOL = "${JUDGE_API_PROTOCOL:-anthropic}" # 可选：openai 时  
降级为 LLM judge（见 test.sh）
```

```
# 兼容旧环境的兜底注入
```

```
EVAL_API_KEY = "${EVAL_API_KEY:-}"
```

```
EVAL_API_BASE = "${EVAL_API_BASE:-}"
```

```
LITELLM_DROP_PARAMS = "true"
```

```
[environment]
```

```
os = "linux"
```

```
build_timeout_sec = 18000.0
```

```
network_mode = "public" # claude-code 框架下不要写 no-network（见 3.2 警示）
```

```
cpus = 2
```

```
memory_mb = 8192
```

```
storage_mb = 30720 # 照抄
```

[复制代码](#)

```
schema_version = "1.4" # 照抄
```

```
# 格式：/app/output/{你的交付物名称}
```

```
artifacts = [  
  "/app/output/FIN-T2-001_财务分析报告.xlsx",  
  "/app/output/FIN-T2-001_毛利率趋势.png",  
  "/logs/artifacts/output",  
]
```

```
[task]
```

```
name = "work/fin1-001" # 任务名称
```

```
version = "1.0.0" # 任务版本
```

```
description = "基于两期年报与交易流水产出财务分析报告" # 任务描述
```

```

[metadata]
task_id = "FIN1-skill-DEP-001" # 题目编号
author_organization = "<供应商名>"
category = "skill-dependency"
domain = "金融" # 所属领域：通用办公/金融/医疗/法律
domain_l2 = "投资银行" # 所属领域二级标签（对齐知识体系表）
capabilities = "财务比率计算、估值口径" # 评测的能力：该任务能评测的具体专业能力
difficulty = "A2" # 难度等级：A1易/A2中/A3难
vl_dependency = "否" # 是否依赖VL（视觉-语言能力）：是/否
source_note = "任务来源、真实性保障、真实场景中的交付物是什么" # 任务说明
tools = "Excel/Python" # 所需工具（办公工具/数据库，Word/Excel/PPT 等）
domain_knowledge = "再融资定增的财务分析口径与可比公司估值方法" # 领域知识依赖（选填）
task_complexity = "C2" #取值C1-C5
weakness_tag = ["W07-流程跳步", "W12-约束遵循"] # 覆盖≥1个，按算法词表填写，至少一项
environment_template = "<平台已确认的环境模板名>"
tool_set = ["filesystem", "shell", "python"] # 按实际可用能力填写
skill_set = [] # 本示例未提供技能；有技能时填写目录名
expected_tool_dependencies = ["filesystem", "shell", "python"] # 按实际必要能力填写
expected_skill_dependencies = [] # 必须是 skill_set 的子集
tags = ["finance", "office", "A2", "skill-dependency", "sop-enforcement", "workflow", "docx", "llm-judge"]
# 逐题填写任务关键词

[[metadata.deliverables]] # 交付物一
path = "FIN-T2-001_财务分析报告.xlsx" # 交付物一的路径
required = true
desc = "主交付物：财务分析报告" # 交付物一的描述

[[metadata.deliverables]] # 见交付物一的说明，如有多个交付物，必须依次写明
path = "FIN-T2-001_毛利率趋势.png"
required = true
desc = "毛利率趋势折线图"

[agent]
timeout_sec = 72000.0 # 缺省 72000;

[verifier]
timeout_sec = 18000.0
user = "root"

```

```

[verifier.env]
# Judge 相关变量统一 JUDGE_ 前缀，只写在 [verifier.env]、严禁写入
[environment.env]。
# 必选项（运行环境注入，AP 必给）；可选项一律用 ${VAR:-默认值} 语法给默认值。
JUDGE_API_KEY = "${JUDGE_API_KEY:-}" # 必选: judge 网关 key
JUDGE_BASE_URL = "${JUDGE_BASE_URL:-}" # 必选: judge 网关地址（可
带 /v1, test.sh 负责剥）
JUDGE_MODEL = "${JUDGE_MODEL:-qwen3.7-plus}" # 可选: 裁判模型（经
REWARDKIT_MODEL 运行时生效）
JUDGE_PROVIDER = "${JUDGE_PROVIDER:-anthropic}" # 可选: 信息性声明
JUDGE_API_PROTOCOL = "${JUDGE_API_PROTOCOL:-anthropic}" # 可选: openai
时降级为 LLM judge（见 test.sh）
# 兼容旧环境的兜底注入
EVAL_API_KEY = "${EVAL_API_KEY:-}"
EVAL_API_BASE = "${EVAL_API_BASE:-}"
LITELLM_DROP_PARAMS = "true"

[environment]
os = "linux"
build_timeout_sec = 18000.0
network_mode = "public" # claude-code 框架下不要写 no-network（见
3.2 警示）
cpus = 2
memory_mb = 8192
storage_mb = 30720 # 照抄

```